

BÁO CÁO THUYẾT MINH ĐỒ ÁN TỐT NGHIỆP

XÂY DỰNG HỆ THỐNG DỰ BÁO NHIỆT ĐỘ THỜI GIAN THỰC DỰA TRÊN CÁC MÔ HÌNH HỌC MÁY VÀ HỌC SÂU CHUỖI THỜI GIAN

LỜI MỞ ĐẦU

1. Lý do chọn đề tài

Biến đổi khí hậu toàn cầu đang diễn ra ngày càng phức tạp, gây ra các hiện tượng thời tiết cực đoan như nắng nóng kéo dài, biến động nhiệt độ đột ngột giữa ngày và đêm, ảnh hưởng trực tiếp đến đời sống sinh hoạt, sản xuất nông nghiệp, điều phối năng lượng điện và sức khỏe con người. Trong số các yếu tố khí tượng, nhiệt độ là tham số quan trọng nhất, có tính chu kỳ cao nhưng cũng chịu ảnh hưởng bởi nhiều yếu tố phi tuyến phức tạp.

Các phương pháp dự báo thời tiết truyền thống thường dựa trên mô hình Vật lý số học (Numerical Weather Prediction - NWP). Mặc dù rất chính xác cho dự báo trung và dài hạn, các mô hình NWP đòi hỏi hạ tầng siêu máy tính cực kỳ đắt đỏ, thời gian tính toán kéo dài và gặp khó khăn trong việc cập nhật dự báo ngắn hạn thời gian thực (real-time hourly forecasting). Với sự phát triển vượt bậc của Trí tuệ Nhân tạo (AI), các mô hình Học máy (Machine Learning) và Học sâu (Deep Learning) đã mở ra một hướng tiếp cận mới: khai thác quy luật tự học từ dữ liệu chuỗi thời gian khí tượng lịch sử với chi phí tính toán thấp hơn nhiều lần và khả năng suy luận tức thời.

Chính vì lý do đó, đề án này đề xuất và hiện thực hóa đề tài: **"Xây dựng hệ thống dự báo nhiệt độ thời gian thực dựa trên các mô hình Học máy và Học sâu chuỗi thời gian"**. Hệ thống không chỉ huấn luyện các mô hình AI dự báo chính xác mà còn được container hóa hoàn chỉnh để tự động cập nhật dữ liệu và hiển thị kết quả trực quan trên giao diện Dashboard.

2. Mục tiêu nghiên cứu của đề án

- **Về mặt dữ liệu:** Thu thập thành công dữ liệu khí tượng lịch sử 10 năm của 3 miền Việt Nam (Hà Nội, Đà Nẵng, TP.HCM), thực hiện làm sạch dữ liệu chuỗi thời gian và xây dựng các đặc trưng trễ (lag), đặc trưng trượt (rolling) để mô hình hóa xu hướng thời tiết.
- **Về mặt mô hình:** Nghiên cứu lý thuyết, huấn luyện và đánh giá đối sánh 3 đại diện mô hình tiêu biểu gồm: Hồi quy tuyến tính (Linear Regression

- Baseline), XGBoost Regressor (Học máy dạng Ensemble), và LSTM (Học sâu mạng nơ-ron hồi quy chuỗi thời gian).
- **Về mặt hệ thống:** Thiết kế và xây dựng một hệ thống hoàn chỉnh tự động hóa luồng dữ liệu thời gian thực: Tự động gọi API lấy dữ liệu thực tế mỗi giờ, suy luận dự báo giờ tiếp theo ($t+1$), lưu cơ sở dữ liệu SQLite, đóng gói đa container bằng Docker Compose và hiển thị Web Dashboard tương tác sinh động.

CHƯƠNG 1: TỔNG QUAN BÀI TOÁN VÀ CÁC PHƯƠNG PHÁP TIẾP CẬN

1.1 Khái quát bài toán dự báo chuỗi thời gian khí tượng

Dự báo thời tiết nói chung và dự báo nhiệt độ nói riêng thực chất là bài toán dự báo chuỗi thời gian (Time Series Forecasting). Dữ liệu khí tượng là tập hợp các quan trắc $X = \{x_1, x_2, \dots, x_t\}$ được ghi nhận theo trình tự thời gian liên tục với khoảng cách đều nhau (ví dụ: mỗi giờ một bản ghi). Mục tiêu của bài toán là dự báo giá trị nhiệt độ tiếp theo y_{t+1} dựa trên tập hợp dữ liệu lịch sử và các yếu tố khí tượng bổ trợ như độ ẩm, lượng mưa, hướng gió, tốc độ gió, áp suất khí quyển.

1.2 Phân tích các phương pháp tiếp cận hiện nay

1.2.1 Phương pháp Dự báo số trị truyền thống (NWP)

Các mô hình NWP (như WRF, GFS) giải các hệ phương trình thủy động lực học biểu diễn chuyển động của khí quyển và trao đổi nhiệt năng.

- **Ưu điểm:** Độ chính xác vật lý cao, có khả năng giải thích tốt cơ chế khí tượng trên diện rộng.
- **Nhược điểm:** Đòi hỏi siêu máy tính (Supercomputer); độ phân giải thời gian thực bị hạn chế (thường chỉ chạy 2-4 lần một ngày); nhạy cảm với sai lệch điều kiện biên ban đầu.

1.2.2 Phương pháp Học máy và Học sâu (Data-driven approach)


Tiếp cận dựa trên dữ liệu coi khí quyển là một "hộp đen" và huấn luyện mô hình ánh xạ các đặc trưng quá khứ sang tương lai.

- **Ưu điểm:**
 - Tốc độ suy luận cực nhanh (chỉ mất vài mili-giây trên phần cứng thông dụng).
 - Tự động phát hiện các mối quan hệ phi tuyến phức tạp giữa độ ẩm, áp suất và nhiệt độ mà các phương trình vật lý khó biểu diễn hết.

- Dễ dàng tích hợp luồng cập nhật dữ liệu tự động thời gian thực.
- **Nhược điểm:** Phụ thuộc hoàn toàn vào chất lượng dữ liệu lịch sử; khó giải thích cơ chế vật lý bên trong mô hình (Black-box).

CHƯƠNG 2: THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

Quy trình xử lý dữ liệu:



2.1 Thu thập dữ liệu qua API Meteostat

Đề án lựa chọn API Meteostat - nguồn dữ liệu khí tượng mở uy tín thế giới, đồng bộ hóa từ mạng lưới các trạm khí tượng quốc gia. Để đảm bảo tính đại diện địa lý cho 3 miền khí hậu Việt Nam, dữ liệu được tải từ năm 2016 đến năm 2026 cho 3 trạm khí tượng lớn:

1. **Hà Nội (Trạm Nội Bài - ID: 48820):** Đại diện khí hậu cận nhiệt đới ẩm phía Bắc, có 4 mùa rõ rệt.
2. **Đà Nẵng (Trạm Đà Nẵng - ID: 48855):** Đại diện khí hậu nhiệt đới gió mùa miền Trung, chịu ảnh hưởng mạnh của biển.
3. **TP. Hồ Chí Minh (Trạm Tân Sơn Nhất - ID: 48900):** Đại diện khí hậu nhiệt đới xavan phía Nam, có hai mùa mưa và khô rõ rệt.

Tổng số dòng dữ liệu thô thu thập được là **273,010 bản ghi theo giờ**.

2.2 Tiền xử lý dữ liệu và làm sạch

Dữ liệu từ trạm đo thực tế không tránh khỏi các lỗi gián đoạn do sự cố kỹ thuật. Quy trình xử lý gồm:

1. **Bổ sung mốc giờ khuyết:** Reindex toàn bộ chuỗi thời gian từ 2016 đến 2026 để đảm bảo khoảng cách giữa các bản ghi luôn là đúng 1 giờ.
2. **Nội suy tuyến tính (Linear Interpolation):** Áp dụng cho các cột liên tục bị thiếu (như temp, rhum, wspd, pres, wdir) để điền giá trị khuyết một cách mượt mà dựa trên xu hướng của các giờ liền kề.
3. **Xử lý cột mưa (prcp):** Điền giá trị 0 cho các dòng trống, giả định rằng những khoảng thời gian trạm đo không ghi nhận lượng mưa đồng nghĩa với việc trời không mưa.
4. **Loại bỏ cột nhiễu:** Các cột có tỷ lệ trống trên 50% (dwpt, snow, wpgt, tsun) được loại bỏ hoàn toàn để tránh làm sai lệch mô hình.

2.3 Kỹ nghệ đặc trưng (Feature Engineering)

Đây là bước cốt lõi giúp các mô hình học máy truyền thống hiểu được yếu tố chuỗi thời gian:

2.3.1 Mã hóa chu kỳ thời gian (Cyclic Time Encoding)

Nếu sử dụng cột số từ 0 đến 23 cho giờ và 1 đến 12 cho tháng, mô hình sẽ coi giờ 23 và giờ 0 rất xa nhau, trong khi thực tế chúng liền kề. Ta biến đổi chúng sang hệ tọa độ Sin/Cos:

$$\begin{aligned} \text{hour_sin} &= \sin((2\pi \times \text{hour}) / 24), & \text{hour_cos} &= \cos((2\pi \times \text{hour}) / 24) \\ \text{month_sin} &= \sin((2\pi \times (\text{month} - 1)) / 12), & \text{month_cos} &= \cos((2\pi \times (\text{month} - 1)) / 12) \end{aligned}$$

Nhờ đó, tính liên tục của thời gian giữa ngày hôm trước và ngày hôm sau được bảo toàn nguyên vẹn.

2.3.2 Đặc trưng trễ (Lag Features)

Tạo ra các cột ghi nhận giá trị của nhiệt độ (temp), độ ẩm (rhum), lượng mưa (prcp) ở thời điểm quá khứ t-1, t-2, t-3, t-6, t-12, t-24. Đặc trưng trễ t-1 mang thông tin cực kỳ mạnh mẽ vì nhiệt độ không thay đổi quá đột ngột chỉ sau 1 giờ.

2.3.3 Đặc trưng thống kê trượt (Rolling Features)

Tính giá trị trung bình trượt (Mean) và độ lệch chuẩn trượt (Std) trong các cửa sổ thời gian 6 giờ và 24 giờ qua. Đặc trưng này giúp mô hình nhận biết được xu hướng tăng/giảm nhiệt độ ngắn hạn và độ biến động của thời tiết.

Dữ liệu sau khi xử lý có tổng cộng **272,938 bản ghi sạch** với đầy đủ 45 đặc trưng đầu vào, lưu vào bảng `processed_weather` của SQLite.

CHƯƠNG 3: CƠ SỞ TOÁN HỌC VÀ CÁC MÔ HÌNH DỰ BÁO

3.1 Mô hình Hồi quy Tuyến tính (Linear Regression)

Mô hình giả định mối quan hệ tuyến tính giữa nhiệt độ cần dự báo y và các đặc trưng đầu vào x :

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = W^T X$$

Huấn luyện mô hình thực chất là giải bài toán tối ưu hóa nhằm cực tiểu hóa hàm mất mát bình phương tối thiểu (MSE):

$$L(W) = (1/N) * \sum (y_i - W^T X_i)^2$$

Mô hình này đơn giản, chạy cực nhanh và đóng vai trò làm mốc đối sánh (Baseline) để đánh giá độ cải tiến của các thuật toán phức tạp hơn.


3.2 Mô hình XGBoost Regressor (Extreme Gradient Boosting)

XGBoost là một thuật toán cực kỳ mạnh mẽ dựa trên cây quyết định tăng cường độ dốc (Gradient Boosted Decision Trees - GBDT). XGBoost xây dựng mô hình dự báo bằng cách kết hợp tuần tự một chuỗi các cây quyết định yếu (weak learners).

Tại mỗi bước, một cây mới được thêm vào để khớp với phần dư (residual error) của các cây trước đó bằng cách tối ưu hóa hàm mục tiêu có chứa thành phần phạt điều hòa (regularization) tránh quá khớp. XGBoost sử dụng xấp xỉ Taylor bậc hai của hàm mất mát để tối ưu hóa cực kỳ nhanh và hỗ trợ xử lý dữ liệu thưa, song song hóa phần cứng tối đa.

3.3 Mạng học sâu LSTM (Long Short-Term Memory)

LSTM là một nhánh đặc biệt của Mạng nơ-ron hồi quy (RNN), được thiết kế để giải quyết vấn đề triệt tiêu đạo hàm (vanishing gradient) khi huấn luyện chuỗi thời gian dài.



Cơ chế cốt lõi của LSTM là **Bộ nhớ trạng thái ô (Cell State - c_t)** được điều phối bởi 3 cổng logic: Cổng quên (Forget Gate), Cổng vào (Input Gate), và Cổng ra (Output Gate). Trong đồ án này, mô hình LSTM nhận đầu vào là chuỗi dữ liệu thô đại diện cho toàn bộ 24 giờ liên tục gần nhất để tự trích xuất quy luật động lực học khí quyển và dự báo nhiệt độ cho giờ thứ 25.

CHƯƠNG 4: THIẾT KẾ VÀ TRIỂN KHAI KIẾN TRÚC HỆ THỐNG

4.1 Kiến trúc hệ thống tổng thể

Hệ thống được thiết kế theo mô hình kiến trúc Microservices hướng dịch vụ, container hóa hoàn chỉnh và điều phối bởi Docker Compose.

```
[Người dùng] <--> [React Frontend] <--> [FastAPI Backend] <--> [SQLite DB]
```

```
[FastAPI Backend] <--> [Inference Engine (AI Models)]
```

```
[Updater Daemon] --> [Meteostat API] (Cập nhật mỗi giờ)
```

```
[Updater Daemon] --> [SQLite DB] (Lưu dự báo & sai số)
```

4.2 Chi tiết các dịch vụ trong hệ thống

4.2.1 Dịch vụ Cập nhật tự động (Updater Daemon Service)

Chạy một tiến trình lặp tuần hoàn (daemon) trong container độc lập. Mỗi 1 giờ, script tự động kích hoạt gọi API lấy dữ liệu thời tiết mới nhất. Tính toán trực tiếp các đặc trưng trễ, trượt và lấy dự báo chu kỳ trước ra đối sánh với thực tế, lưu sai số. Cuối cùng tải mô hình AI chạy suy luận cho giờ tiếp theo.

4.2.2 Dịch vụ API Backend (FastAPI Service)

Viết bằng FastAPI giúp xử lý bất đồng bộ hiệu năng cao. Nạp sẵn mô hình AI lên RAM để tối ưu thời gian phản hồi. Cung cấp các endpoint trả về thời tiết hiện tại, chuỗi dự báo 7 ngày, lịch sử sai số và các chỉ số MAE, RMSE, MAPE.

4.2.3 Dịch vụ Giao diện người dùng (Frontend Service)

Xây dựng bằng ReactJS kết hợp Recharts. Giao diện thiết kế tối giản, hỗ trợ Dark Mode và đáp ứng tốt trên thiết bị di động, được phục vụ qua Nginx để tối ưu hóa tốc độ tải trang.

CHƯƠNG 5: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

5.1 Thiết lập thực nghiệm

- **Dữ liệu phân chia:** Tập Train (2016-2024: 236,437 dòng), tập Test (2025 - 05/2026: 36,501 dòng).
- **Môi trường:** Apple Silicon M2, RAM 8GB.
- **Thư viện:** scikit-learn, xgboost, tensorflow/keras.

5.2 Các chỉ số đánh giá sai số toán học

- **MAE (Sai số tuyệt đối trung bình):** Đo lường sai lệch trung bình tuyệt đối.
- **RMSE (Căn sai số bình phương trung bình):** Phạt nặng các dự báo có sai số lớn.
- **MAPE (Sai số phần trăm tuyệt đối trung bình):** Thể hiện sai số theo tỷ lệ %.

5.3 Kết quả so sánh sai số trên tập Test

Mô hình	MAE (°C)	RMSE (°C)	MAPE (%)
Linear Regression (Baseline)	0.336	0.452	1.326%
XGBoost Regressor	0.316	0.440	1.250%
LSTM Deep Learning	0.731	0.942	2.811%

5.4 Nhận xét và thảo luận chuyên sâu

1. Hiệu năng vượt trội của XGBoost: Mô hình XGBoost đạt sai số tuyệt đối trung bình cực kỳ thấp (chỉ 0.316°C). Điều này chứng minh rằng đối với bài toán dự báo ngắn hạn 1 giờ tiếp theo, các đặc trưng trễ cực ngắn hạn có mối tương quan mạnh mẽ.

2. Đánh giá mô hình Baseline Hồi quy Tuyến tính: Mô hình Baseline đạt kết quả rất tốt (MAE 0.336°C), chỉ ra rằng mối quan hệ nhiệt độ hiện tại và 1 giờ trước mang tính chất tuyến tính cao, nhưng sẽ gặp khó khăn khi thời tiết biến động đột biến hoặc dự báo xa hơn.

3. Đánh giá mô hình Học sâu LSTM: Sai số MAE là 0.731°C, cao hơn XGBoost vì LSTM phải tự học trích xuất đặc trưng chuỗi thời gian từ tập dữ liệu thô. Tuy nhiên, sai số dưới 1°C chứng minh mạng nơ-ron hồi quy có khả năng tự học rất tốt quy luật tuần hoàn ngày đêm của thời tiết.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Những kết quả đã đạt được

- Hoàn thành quy trình khoa học dữ liệu từ thu thập dữ liệu thô, tiền xử lý, kỹ nghệ đặc trưng.
- Cả 3 mô hình đều đạt độ chính xác cao với sai lệch thực tế trung bình dưới 1°C trên tập kiểm thử độc lập.
- Triển khai thành công kiến trúc microservices đóng gói bằng Docker Compose, tự động hóa cập nhật và đối chiếu trên Dashboard.

2. Hạn chế và Hướng phát triển

- **Hạn chế:** Mới chỉ tập trung dự báo mốc giờ tiếp theo (t+1); chưa cấu hình cơ chế tự động tái huấn luyện (Continuous Training) chống Model Drift.
- **Hướng phát triển:** Mở rộng dự báo đa bước thời gian (Multi-step); Tích hợp thêm đặc trưng ảnh vệ tinh/gió; Xây dựng hệ thống cảnh báo thời tiết cực đoan qua Telegram/Email.